

Aplicación de técnicas de Machine Learning para realizar predicciones de capturas de camarón de profundidad en Chile

Regularización en Regresión Lineal Múltiple Ridge, LASSO, Elastic Net e Interpretación Bayesiana

Dr. Carlos Montenegro Silva & Maximiliano Zilleruelo León

2026-08-03

Propósito de la presentación


Esta presentación estudia métodos de regularización para **regresión lineal múltiple**.

El objetivo no es reemplazar la regresión lineal clásica, sino comprender cómo modificarla cuando el modelo tiene muchas variables, predictores correlacionados o riesgo de sobreajuste.

Al finalizar, se espera que los participantes puedan:

- explicar por qué un estimador sesgado puede predecir mejor que uno insesgado;
- formular Ridge, LASSO y Elastic Net;
- elegir el parámetro de penalización mediante validación cruzada;
- interpretar Ridge y LASSO desde una perspectiva bayesiana;
- implementar estos métodos en R.

¿Dónde se ubica la regularización dentro de la IA?



Ridge, LASSO y Elastic Net son técnicas de regularización que se utilizan en **aprendizaje supervisado** para problemas de **regresión** (variables respuesta continuas) dentro del ML.


La regularización tiene una doble identidad.

Desde la estadística, se entiende como una modificación del estimador de mínimos cuadrados que introduce sesgo para reducir varianza.

Desde Machine Learning, se entiende como una estrategia para controlar la complejidad del modelo y mejorar su capacidad de generalización.

La misma técnica conecta inferencia estadística, predicción y aprendizaje supervisado.

¿Qué problema resuelve la regularización?



Punto de partida: regresión lineal múltiple

La regresión lineal múltiple modela una variable respuesta continua como combinación lineal de varias variables predictoras:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2).$$

En forma matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Esta formulación es simple, interpretable y muy poderosa. Sin embargo, su desempeño depende fuertemente de la calidad de la matriz de diseño $\mathbf{X}$.

Mínimos cuadrados ordinarios

El estimador de mínimos cuadrados ordinarios, EMCO o MCO, se obtiene minimizando la suma de cuadrados residual:

$$RSS(\beta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2.$$

Si $X^T X$ es invertible, el estimador tiene forma cerrada:

$$\hat{\beta}_{OLS} = (X^T X)^{-1} X^T \mathbf{y}.$$

La elegancia de esta expresión también revela su fragilidad: todo depende de que $X^T X$ pueda invertirse de manera estable.

Gauss–Markov y una pregunta clave

Bajo los supuestos clásicos, el teorema de Gauss–Markov establece que MCO es el estimador lineal insesgado de mínima varianza.

Esto parece una ventaja definitiva, pero contiene una restricción importante: la comparación se hace dentro de la clase de estimadores **lineales e insesgados**.

La regularización plantea una pregunta distinta:

¿Podemos aceptar algo de sesgo para reducir mucho la varianza?

Esa pregunta será el hilo conductor de la unidad.

Cuando MCO puede fallar

MCO puede ser inestable en varios escenarios frecuentes:

- hay muchas variables predictoras;
- algunas variables explican información muy parecida;
- existe multicolinealidad;
- p es cercano a n ;
- el modelo se ajusta demasiado a la muestra de entrenamiento;
- se busca buena predicción en datos nuevos, no sólo buen ajuste retrospectivo.

En estos casos, pequeños cambios en los datos pueden producir grandes cambios en los coeficientes estimados.

Un modelo sobreajustado aprende no sólo la señal sistemática, sino también ruido específico de la muestra.

En entrenamiento puede tener un error muy bajo, pero en datos nuevos su rendimiento puede deteriorarse.

Buen ajuste en la muestra no garantiza buena predicción fuera de la muestra.

La regularización busca controlar la complejidad efectiva del modelo para mejorar su capacidad de generalización.

La multicolinealidad aparece cuando una o más variables predictoras pueden aproximarse mediante combinaciones lineales de otras.

Cuando esto ocurre, $X^T X$ puede volverse casi singular. Como consecuencia:

- los coeficientes pueden tener varianzas grandes;
- los signos pueden ser difíciles de interpretar;
- la predicción puede ser sensible a pequeñas perturbaciones;
- la estimación puede depender demasiado de la muestra observada.

Ridge fue diseñado precisamente para estabilizar este tipo de situaciones.

Error cuadrático medio

Para un estimador $\hat{\theta}$ de un parámetro θ , el error cuadrático medio se define como:

$$\text{ECM}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Puede descomponerse como:

$$\text{ECM}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Sesgo}(\hat{\theta})^2.$$

Esta identidad es central: un estimador puede tener mayor sesgo, pero menor ECM total si logra reducir suficientemente la varianza.

Error de entrenamiento y error de prueba

El **error de entrenamiento** mide qué tan bien el modelo reproduce los datos con que fue estimado.

El **error de prueba mide** qué tan bien predice observaciones no utilizadas durante la estimación.

La regularización suele aumentar levemente el error de entrenamiento, pero puede reducir el error de prueba.

El objetivo no es ajustar perfectamente el pasado, sino predecir mejor el futuro.

Regularización como idea general

Los métodos de regularización ajustan el modelo usando todas o parte de las variables disponibles, pero restringen el tamaño de los coeficientes.

En lugar de minimizar sólo:

$$RSS(\beta),$$

minimizan una función del tipo:

$$RSS(\beta) + \lambda P(\beta),$$

donde $P(\beta)$ es una penalización y $\lambda \geq 0$ controla su intensidad.

Dos formas de estimar parámetros

En los modelos lineales regularizados no basta con escribir la función objetivo. También debemos preguntarnos cómo se obtienen los coeficientes.

Existen dos situaciones generales:

- problemas con **solución analítica cerrada**, donde podemos escribir directamente una fórmula para $\hat{\beta}$;
- problemas sin solución cerrada simple, donde se necesitan **algoritmos iterativos**.

Esta distinción es central para entender por qué Ridge es computacionalmente más directo que LASSO y Elastic Net.

Ridge surge como respuesta a un problema concreto: la inestabilidad de MCO cuando hay predictores correlacionados o cuando $X^T X$ está mal condicionada.

La idea es simple:

mantener todas las variables, pero reducir el tamaño de sus coeficientes.

Ridge no busca seleccionar variables. Busca estabilizar la estimación.

Función objetivo de Ridge

Ridge estima los coeficientes resolviendo:

$$\hat{\beta}_{Ridge} = \arg \min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

La penalización $\sum_{j=1}^p \beta_j^2$ corresponde a la norma L_2 al cuadrado.

Para mayores detalles de las norma de vectores ver Apéndice.

El intercepto β_0 normalmente no se penaliza.

La penalización L_2 es pequeña cuando los coeficientes están cerca de cero.

Por eso, Ridge prefiere soluciones con coeficientes moderados, aun cuando eso implique sacrificar algo de ajuste dentro de la muestra.

Ridge reduce varianza a cambio de introducir sesgo.

Este intercambio puede reducir el error de predicción en datos nuevos.

Ridge y multicolinealidad

Cuando dos predictores están altamente correlacionados, MCO puede asignar un coeficiente grande y positivo a uno, y uno grande y negativo al otro.

Ridge tiende a repartir el efecto de forma más estable entre variables correlacionadas.

Por eso, Ridge suele ser una buena opción cuando:

- muchas variables contienen señal parcial;
- hay grupos de variables correlacionadas;
- interesa predicción más que selección de variables;
- se quiere evitar estimaciones extremadamente variables.

Ridge no es insesgado. En general:

$$\mathbb{E}[\hat{\beta}_{Ridge}] \neq \beta.$$

Pero esto no necesariamente es malo.


El punto central es que el aumento de sesgo puede ser compensado por una reducción importante de varianza.

Por eso, Ridge puede tener menor ECM que MCO.

Efecto conceptual de λ en Ridge

A medida que λ aumenta, los coeficientes Ridge se acercan gradualmente a cero.

Sin embargo, en general no se hacen exactamente cero.



Ridge encoge suavemente los coeficientes, pero no realiza selección automática de variables.

El valor de λ debe elegirse con criterio predictivo.

Una estrategia común es la validación cruzada:

1. Dividir los datos en subconjuntos.
2. Ajustar el modelo para distintos valores de λ .
3. Calcular el error de predicción en datos no usados para entrenar.
4. Elegir el λ con menor error promedio.

Una opción alternativa es utilizar inferencia bayesiana y asignar una distribución a priori informativa para λ .

Validación cruzada


La validación cruzada estima el error fuera de muestra usando sólo los datos disponibles.

En K -fold cross-validation:

- se divide la muestra en K partes;
- se entrena con $K - 1$ partes;
- se valida (o testesa) con la parte restante;
- se repite el proceso hasta que todas las partes hayan sido usadas para validar.

El resultado es una estimación más estable del error predictivo.

Ridge: selección de λ mediante validación cruzada



La validación cruzada es el procedimiento; lo que se minimiza es el ECM promedio de validación.

Ridge: matriz de errores para K folds y P valores de λ

Fold	λ_1	λ_2	$\dots$	λ_j	λ_P
F_1	ECM_{11}	ECM_{12}	$\dots$	ECM_{1j}	ECM_{1P}
F_2	ECM_{21}	ECM_{22}	$\dots$	ECM_{2j}	ECM_{2P}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
F_K	ECM_{K1}	ECM_{K2}	$\dots$	ECM_{Kj}	ECM_{KP}
Promedio	$\overline{ECM}_1$	$\overline{ECM}_2$	$\dots$	$\overline{ECM}_j$	$\overline{ECM}_P$

↓

$$\lambda^* = \lambda_j \text{ si } \overline{ECM}_j \text{ es el menor ECM promedio}$$

↓

$$\text{Estimar } \hat{\beta} \text{ Ridge final con todos los datos y } \lambda^* \text{ fijo}$$

Promedio vertical: ECM medio de validación cruzada para cada λ .

Interpretación de resultados Ridge

Al interpretar un modelo Ridge se recomienda observar:

- el valor seleccionado de λ ;
- el error de validación cruzada;
- la magnitud relativa de los coeficientes;
- la estabilidad del modelo frente a variables correlacionadas;
- la capacidad predictiva en datos nuevos.

Ridge no entrega selección automática de variables, por lo que no debe usarse si el objetivo principal es obtener un subconjunto pequeño de predictores.

Ridge estabiliza los coeficientes, pero mantiene todas las variables en el modelo.

En muchos problemas, se sospecha que sólo algunas variables son realmente importantes.

LASSO responde a una pregunta distinta:

¿Podemos regularizar y seleccionar variables al mismo tiempo?

La respuesta es sí, usando una penalización L_1 .

Función objetivo de LASSO

LASSO estima los coeficientes resolviendo:

$$\hat{\beta}_{LASSO} = \arg \min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

La penalización $\sum_{j=1}^p |\beta_j|$ corresponde a la norma L_1 .

Idea clave de LASSO

A diferencia de Ridge, LASSO puede hacer que algunos coeficientes sean exactamente cero.

Esto significa que LASSO realiza selección de variables automáticamente.

LASSO combina predicción y selección de variables.

Por eso es especialmente útil cuando se espera que sólo un subconjunto de predictores sea relevante.

- Si $\lambda = 0$, LASSO coincide con MCO.
- Si λ aumenta, los coeficientes se encogen hacia cero.
- Si λ es suficientemente grande, varios coeficientes se vuelven exactamente cero.

El número de variables seleccionadas depende directamente de λ .

Efecto conceptual de λ en LASSO

En LASSO, algunos coeficientes llegan exactamente a cero a medida que aumenta λ .

Muchas variables
activas


Algunos coeficientes
se anulan

Modelo más
parsimonioso

→ λ aumenta

LASSO encoge coeficientes y puede hacer selección automática de variables.

LASSO: selección de λ y estimación de coeficientes



Dos tareas distintas

La validación cruzada selecciona λ comparando el ECM promedio de validación; el descenso por coordenadas estima los coeficientes para cada valor de la grilla. La penalización L_1 permite que algunos coeficientes sean exactamente cero.

Cuando un coeficiente estimado es exactamente cero, la variable correspondiente queda excluida del modelo.

Esto facilita:

- interpretación;
- comunicación de resultados;
- construcción de modelos más parsimoniosos;
- reducción de variables irrelevantes.

Sin embargo, la selección puede ser inestable si hay predictores muy correlacionados.

LASSO y variables correlacionadas

Cuando dos variables están fuertemente correlacionadas, LASSO puede seleccionar una y descartar otra, incluso si ambas contienen información parecida.

Esto puede ser útil para parsimonia, pero también puede generar inestabilidad interpretativa.

En problemas con grupos de variables correlacionadas, Elastic Net suele ser una alternativa más robusta.

Interpretación de resultados LASSO

Al interpretar LASSO conviene distinguir dos niveles:

1. **Predicción:** qué tan bien predice el modelo.
2. **Selección:** qué variables permanecen con coeficientes distintos de cero.

Un coeficiente cero no necesariamente significa que la variable sea inútil en sentido causal. Significa que, bajo la penalización seleccionada y los datos disponibles, no aporta suficiente información predictiva adicional.

Ridge maneja bien la multicolinealidad, pero no selecciona variables.

LASSO selecciona variables, pero puede ser inestable cuando hay grupos de predictores correlacionados.

Elastic Net combina ambas ideas:

regularización L_1 para selección y L_2 para estabilidad.

Función objetivo de Elastic Net

Elastic Net resuelve:

$$\hat{\beta}_{EN} = \arg \min_{\beta} \left\{ RSS(\beta) + \lambda \left[(1 - \alpha) \frac{1}{2} \sum_{j=1}^p \beta_j^2 + \alpha \sum_{j=1}^p |\beta_j| \right] \right\}.$$

Aquí:


- λ controla la intensidad total de la penalización;
- α controla la mezcla entre Ridge y LASSO.

Elastic Net contiene a Ridge y LASSO como casos especiales:

- si $\alpha = 0$, se obtiene Ridge;
- si $\alpha = 1$, se obtiene LASSO;
- si $0 < \alpha < 1$, se obtiene una combinación de ambos.

Esto permite adaptar el método al tipo de estructura presente en los datos.

Elastic Net: selección conjunta de α y λ



Para cada valor de α se evalúa una grilla de λ ; el par final minimiza el ECM promedio de validación.

Efecto agrupamiento

Cuando varias variables están altamente correlacionadas, Elastic Net tiende a mantenerlas juntas con coeficientes similares.

Este comportamiento se conoce como efecto agrupamiento.

Es útil cuando un conjunto de variables representa un mismo fenómeno subyacente y no se desea que el algoritmo seleccione arbitrariamente sólo una de ellas.

Métricas de desempeño predictivo

Sea y_i el valor observado, $\hat{y}_i$ la predicción y n el número de observaciones.

RMSE: raíz del error cuadrático medio

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

Penaliza con mayor intensidad los errores grandes y se expresa en las mismas unidades de la respuesta.

MAE: error absoluto medio

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

Es más robusto frente a observaciones con errores extremos.

MAPE: error porcentual absoluto medio

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|.$$

Facilita una interpretación porcentual, pero no debe utilizarse cuando $y_i = 0$ y puede ser inestable cuando y_i está muy cerca de cero.

R^2 : coeficiente de determinación

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Mide cuánto mejora el modelo respecto de predecir siempre la media $\bar{y}$.

Para comparar modelos, estas métricas deben calcularse sobre datos no usados en el ajuste a través de validación cruzada.

Cuándo usar Ridge

Ridge suele ser recomendable cuando:

- hay muchas variables correlacionadas;
- se espera que muchas variables tengan efectos pequeños o moderados;
- el objetivo principal es predicción;
- no se requiere selección automática de variables;
- se desea estabilizar un modelo lineal.

Cuándo usar LASSO

LASSO suele ser recomendable cuando:

- se espera que pocas variables sean relevantes;
- se busca un modelo interpretable y parsimonioso;
- hay muchas variables candidatas;
- se desea hacer selección automática de predictores.

Debe usarse con cautela si hay fuerte correlación entre predictores.

Elastic Net suele ser recomendable cuando:

- hay muchas variables;
- hay grupos de variables correlacionadas;
- se desea selección de variables sin perder demasiada estabilidad;
- LASSO parece demasiado inestable;
- Ridge mantiene demasiadas variables para los fines del análisis.

Ejemplo aplicado: base de datos de bitacoras de pesca

El ejemplo se realizó sobre una base de datos de la pesquería comercial de camarón nylon (*Heterocarpus reedi*) de Chile. Cada registro contiene información operacional, espacial y temporal asociada a la actividad extractiva, la cual fue utilizada para modelar y predecir la captura por lance, definida como la variable respuesta del estudio.

El propósito del estudio es observar qué cambia cuando una misma base de datos se ajusta mediante Ridge, LASSO y Elastic Net.

¿Por qué ampliar la base?

Se construye un problema suficientemente desafiante para que sean visibles:

- la multicolinealidad;
- la presencia de predictores irrelevantes;
- la no linealidad;
- la diferencia entre contracción y selección de variables.



Base utilizada en el ejemplo

La base empleada en los tres modelos contiene **500 observaciones**.

Componente	Cantidad
Variable respuesta: KILOS	1
Variables numéricas originales	3
Variables categóricas originales	11
Términos polinomiales agregados	6
Interacciones agregadas	3
Copias correlacionadas agregadas	15
Variables irrelevantes agregadas	12
Predictores totales	50


Variable respuesta: captura por lance

Estadístico	Valor
Observaciones	500
Media	735,9
Mediana	572,0
Desv. estándar	588,4
Coef. variación	80.0%
Q1	340,0
Q3	952,0
Mínimo	17,0
Máximo	4.100,0



La distribución es marcadamente asimétrica hacia la derecha: la media supera a la mediana y existen lances con capturas muy altas. La descripción corresponde a las 500 observaciones utilizadas en el ejercicio.

Captura media según factores originales



Los promedios describen asociaciones marginales y no efectos causales aislados. Las diferencias pueden reflejar simultáneamente cambios temporales, espaciales, de profundidad y de operación de la flota.

Variables numéricas y categóricas

Numéricas originales

- `latitud`
- `PROF_MED`
- `HORAS_ARR`


Categóricas

- `barco y puerto`;
- `año, mes y día`;
- `semestre`;
- `región y macrozona`;
- `categoría de profundidad`.

Como ya fue mencionado, la variable respuesta es la captura por lance, medida en kilogramos.


Grupo agregado	Cantidad	Finalidad
Cuadrados y cubos	6	Incorporar relaciones no lineales.
Interacciones	3	Representar efectos conjuntos.
Copias correlacionadas	15	Introducir multicolinealidad.
Variables irrelevantes	12	Evaluar selección y contracción.

División entrenamiento y test




Los tres modelos utilizan exactamente la misma partición y los mismos pliegues.

Ridge: validación cruzada




- Penalización exclusivamente cuadrática: $\alpha = 0$.
- Reduce la magnitud de todos los coeficientes.
- No produce ceros exactos.

Ridge: coeficientes principales




Ridge distribuye el efecto entre predictores correlacionados y conserva prácticamente toda la estructura.

LASSO: validación cruzada




- Penalización absoluta: $\alpha = 1$.
- Contrae los coeficientes.
- Lleva algunos de ellos exactamente a cero.

LASSO: coeficientes principales




LASSO produce la solución más directamente interpretable cuando muchos predictores reciben coeficiente cero.

Elastic Net: selección de hiperparámetros



Elastic Net requiere elegir simultáneamente α y λ .

Elastic Net: validación cruzada



Con $0 < \alpha < 1$, combina la penalización de Ridge y LASSO.

Hiperparámetros seleccionados

Método	α	λ_{min}	λ_{1se}	RMSE valid.	Coef. no cero
Ridge	0.0	1111	6470	492.7	175
LASSO	1.0	33.29	79.1	491.9	30
Elastic Net	0.2	156.5	349.5	490.9	49


Parámetros que definen el método

- Ridge: $\alpha = 0$ fijo.
- LASSO: $\alpha = 1$ fijo.
- Elastic Net: α se selecciona en una grilla; aquí se obtuvo $\alpha = 0.2$.

Lectura de λ

- λ_{min} minimiza el error promedio de validación.
- λ_{1se} es más conservador y produce mayor regularización.
- Los valores de λ no son comparables de manera aislada entre métodos: dependen de la penalización y de la escala interna del ajuste.

Elastic Net: coeficientes principales




Elastic Net puede conservar grupos de variables correlacionadas y, al mismo tiempo, eliminar predictores irrelevantes.

Métricas de comparación


Método	RMSE	MAE	MAPE (%)	R^2
Ridge	628.30	441.39	133.54	0.168
LASSO	601.06	432.30	123.19	0.238
Elastic Net	604.44	433.22	125.00	0.230

Todas las métricas se calculan exclusivamente con las 100 observaciones de test.


Comparación del RMSE



Comparación de R^2



Complejidad de los modelos



La principal diferencia entre los métodos puede estar en la parsimonia, incluso cuando sus errores predictivos son similares.

Variables retenidas y eliminadas

Método	Total	No nulos	En cero
Ridge	176	175	1
LASSO	176	30	146
Elastic Net	176	49	127

Ridge conserva prácticamente todos los predictores; LASSO y Elastic Net realizan selección explícita.

¿Qué aporta Ridge?

Fortalezas

- Estabiliza la estimación ante multicolinealidad.
- Distribuye el efecto entre predictores correlacionados.
- Suele ser estable cuando muchas variables aportan información.

Limitación

No genera selección automática: mantiene todos o casi todos los predictores.

¿Qué aporta LASSO?

Fortalezas

- Produce modelos parsimoniosos.
- Facilita la interpretación.
- Elimina predictores irrelevantes mediante ceros exactos.

Limitación

Puede seleccionar arbitrariamente una variable entre varias muy correlacionadas.

¿Qué aporta Elastic Net?

Fortalezas

- Combina contracción y selección.
- Puede conservar grupos de variables correlacionadas.
- Es flexible ante estructuras complejas.

Limitación

Requiere seleccionar dos hiperparámetros: α y λ .

¿Cuándo conviene utilizar cada método?

Situación	Método sugerido
Multicolinealidad fuerte y muchas variables informativas	Ridge
Necesidad de selección automática e interpretación	LASSO
Variables correlacionadas y necesidad de selección	Elastic Net
Prioridad absoluta en estabilidad predictiva	Ridge / Elastic Net
Prioridad absoluta en parsimonia	LASSO

Conclusiones del caso aplicado

- Los tres métodos se ajustaron con la misma base, la misma partición y los mismos pliegues.
- Las métricas de test comparan desempeño predictivo.
- El número de coeficientes no nulos compara complejidad e interpretabilidad.
- La regularización no solo modifica el error: también cambia la estructura del modelo.

La elección final depende del equilibrio entre predicción, estabilidad y parsimonia.

Cierre

La regularización modifica el problema de mínimos cuadrados agregando una penalización sobre los coeficientes.

Esta penalización introduce sesgo, pero puede reducir la varianza y mejorar la predicción.

El parámetro λ es central porque controla la intensidad de la regularización.

La selección de λ debe basarse en desempeño predictivo, usualmente mediante validación cruzada.

- Ridge es útil para estabilizar modelos con multicolinealidad.
- LASSO es útil para selección automática de variables.
- Elastic Net combina estabilidad y selección.
- La estandarización de predictores es indispensable.
- La regularización se entiende tanto como optimización penalizada como estimación MAP.

Conclusión general

La regresión lineal múltiple regularizada mantiene la interpretabilidad del modelo lineal, pero mejora su comportamiento en escenarios de alta dimensionalidad, multicolinealidad y riesgo de sobreajuste.

Regularizar es aceptar un poco de sesgo para ganar estabilidad y capacidad predictiva.

Implementación en R: paquete `glmnet`

El paquete `glmnet` permite ajustar modelos lineales regularizados mediante Ridge, LASSO y Elastic Net de manera eficiente.

- `glmnet()`: ajusta la trayectoria de modelos para una grilla de valores de λ ; $\alpha = 0$ corresponde a Ridge, $\alpha = 1$ a LASSO y $0 < \alpha < 1$ a Elastic Net.
- `cv.glmnet()`: selecciona λ mediante validación cruzada y entrega, entre otros, `lambda.min` y `lambda.1se`.
- `coef()`: extrae los coeficientes estimados para un valor específico de λ .
- `predict()`: obtiene predicciones del modelo para nuevos datos.
- `plot()`: permite visualizar la trayectoria de coeficientes o los resultados de la validación cruzada.

En Elastic Net, α se evalúa externamente sobre una grilla y, para cada valor de α , `cv.glmnet()` selecciona λ .

Apéndice

Una norma es una forma de medir el tamaño o longitud de un vector.

Si el vector de coeficientes es

$$\beta = (\beta_1, \dots, \beta_p)^T,$$

entonces una norma resume en un solo número cuán grandes son esos coeficientes.

En regularización, la norma no se usa sólo como una medida descriptiva: se incorpora a la función objetivo como una penalización.

Penalizar una norma significa desincentivar coeficientes demasiado grandes.

Subíndice y superíndice en $\|\beta\|_2^2$

La expresión

$$\|\beta\|_2^2$$

se lee como: **norma dos del vector β , elevada al cuadrado.**

El subíndice 2 indica que se usa la norma Euclidiana o norma L_2 :

$$\|\beta\|_2 = \sqrt{\beta_1^2 + \cdots + \beta_p^2}.$$

El superíndice 2 indica que esa longitud se eleva al cuadrado:

$$\|\beta\|_2^2 = \beta_1^2 + \cdots + \beta_p^2.$$

Ejemplo numérico de norma L_2

Si

$$\beta = (2, -1, 3)^T,$$

entonces

$$\|\beta\|_2 = \sqrt{2^2 + (-1)^2 + 3^2} = \sqrt{14}.$$

Pero Ridge usa la norma al cuadrado:

$$\|\beta\|_2^2 = 2^2 + (-1)^2 + 3^2 = 14.$$

Por tanto, Ridge penaliza la **suma de cuadrados de los coeficientes**.

¿Por qué Ridge usa $\|\beta\|_2^2$?

La penalización cuadrática tiene tres consecuencias importantes:

- castiga fuertemente coeficientes muy grandes;
- produce una función objetivo suave y derivable;
- permite obtener una solución analítica cerrada.

Por eso Ridge minimiza

$$\|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda\|\beta\|_2^2.$$

La primera parte mide el error de ajuste. La segunda parte controla el tamaño de los coeficientes.

Derivación de las ecuaciones normales

Para MCO:

$$f(\beta) = \|\mathbf{y} - X\beta\|_2^2.$$

Expandiendo:

$$f(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T X^T \mathbf{y} + \beta^T X^T X \beta.$$

Derivando e igualando a cero:

$$-2X^T \mathbf{y} + 2X^T X \hat{\beta} = 0.$$

Por tanto:

$$X^T X \hat{\beta} = X^T \mathbf{y}.$$

Derivación de la solución Ridge

Para Ridge:

$$f(\beta) = \|\mathbf{y} - X\beta\|_2^2 + \lambda\|\beta\|_2^2.$$

El gradiente es:

$$\nabla f(\beta) = -2X^T(\mathbf{y} - X\beta) + 2\lambda\beta.$$

Igualando a cero:

$$X^T X \hat{\beta} + \lambda I \hat{\beta} = X^T \mathbf{y}.$$

Luego:

$$\hat{\beta}_{Ridge} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}.$$

MCO, Ridge, LASSO y Elastic Net son problemas convexos.

Ridge es estrictamente convexo cuando $\lambda > 0$, lo que garantiza una solución única incluso cuando $X^T X$ no es invertible.

LASSO y Elastic Net también son convexos, pero la penalización L_1 introduce puntos no diferenciables. Esa propiedad es la que permite la esparsidad, pero obliga a usar algoritmos especializados.

La no diferenciabilidad en cero es una dificultad computacional, pero también es la fuente de la selección de variables.

Gradiente descendente: idea general

Muchos algoritmos de optimización se basan en una idea simple: partir desde un valor inicial y moverse en la dirección que reduce la función objetivo.

Para una función diferenciable $f(\beta)$, el gradiente descendente actualiza:

$$\beta^{(t+1)} = \beta^{(t)} - \eta \nabla f(\beta^{(t)}),$$

donde $\eta > 0$ es la tasa de aprendizaje.

La intuición es directa: el gradiente indica la dirección de mayor aumento; por eso nos movemos en la dirección opuesta.

Gradiente descendente para MCO y Ridge

Para MCO, la función objetivo es:

$$f(\beta) = \|\mathbf{y} - X\beta\|_2^2.$$

Su gradiente es:

$$\nabla f(\beta) = -2X^T(\mathbf{y} - X\beta).$$

Para Ridge, la función objetivo es:

$$f(\beta) = \|\mathbf{y} - X\beta\|_2^2 + \lambda\|\beta\|_2^2,$$

y el gradiente queda:

$$\nabla f(\beta) = -2X^T(\mathbf{y} - X\beta) + 2\lambda\beta.$$

Aunque Ridge tiene solución cerrada, también puede estimarse con

Descenso por coordenadas

El descenso por coordenadas actualiza un coeficiente a la vez, manteniendo los demás fijos.

La lógica es:

1. fijar todos los coeficientes excepto β_j ;
2. actualizar β_j resolviendo un problema unidimensional;
3. repetir el proceso para $j = 1, \dots, p$;
4. iterar hasta convergencia.

Este enfoque es especialmente importante para LASSO y Elastic Net, y es la base de implementaciones ampliamente usadas como `glmnet`.

En LASSO, la actualización por coordenadas suele expresarse mediante el operador de umbral suave:

$$S(z, \gamma) = \text{sign}(z)(|z| - \gamma)_+.$$

Este operador tiene una interpretación muy importante:

- si $|z| \leq \gamma$, el coeficiente se vuelve exactamente cero;
- si $|z| > \gamma$, el coeficiente se reduce hacia cero, pero no desaparece.

Esta es la razón algorítmica detrás de la selección automática de variables en LASSO.

Elastic Net combina penalización L_1 y L_2 :

$$\min_{\beta} \|\mathbf{y} - X\beta\|_2^2 + \lambda [\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2] .$$

Como incluye una componente L_1 , tampoco tiene una solución cerrada simple en el caso general.

En la práctica se estima mediante descenso por coordenadas, buscando simultáneamente un equilibrio entre selección de variables y estabilidad numérica.

¿Qué es un estimador MAP?

MAP significa **Maximum A Posteriori**, o **máximo a posteriori**.

A diferencia de MLE, que usa sólo la verosimilitud, MAP combina dos fuentes de información:

- la información contenida en los datos, $p(\mathbf{y} \mid \beta)$;
- la información previa sobre los parámetros, $p(\beta)$.

Por el teorema de Bayes:

$$p(\beta \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \beta)p(\beta)}{p(\mathbf{y})}.$$

El estimador MAP elige el valor de β donde la distribución posterior alcanza su máximo.

Cómo se estima usando MAP

El estimador MAP se define como:

$$\hat{\beta}_{MAP} = \arg \max_{\beta} p(\beta \mid \mathbf{y}).$$

Como $p(\mathbf{y})$ no depende de β , podemos escribir:

$$\hat{\beta}_{MAP} = \arg \max_{\beta} p(\mathbf{y} \mid \beta) p(\beta).$$

Aplicando logaritmos:

$$\hat{\beta}_{MAP} = \arg \max_{\beta} \{ \log p(\mathbf{y} \mid \beta) + \log p(\beta) \}.$$

El logaritmo transforma productos en sumas y facilita la optimización.

MAP como minimización penalizada

Maximizar la posterior es equivalente a minimizar el negativo del logaritmo posterior:

$$\hat{\beta}_{MAP} = \arg \min_{\beta} \{ -\log p(\mathbf{y} \mid \beta) - \log p(\beta) \}.$$

Esta expresión revela la conexión con la regularización:

- $-\log p(\mathbf{y} \mid \beta)$ mide el ajuste a los datos;
- $-\log p(\beta)$ actúa como penalización.

La penalización regularizada puede verse como el negativo del log-prior.

Para una revisión detallada de la estimación Bayesiana MAP revisar Apéndice.

MLE, MAP y regularización

Enfoque	Objetivo	Información usada	Resultado
MLE	Maximizar $p(\mathbf{y} \beta)$	Sólo datos	MCO bajo errores normales
MAP Ridge	Maximizar $p(\beta \mathbf{y})$	Datos + prior normal	Ridge
MAP LASSO	Maximizar $p(\beta \mathbf{y})$	Datos + prior Laplace	LASSO

La regularización puede entenderse como una forma de incorporar supuestos previos sobre el tamaño esperado de los coeficientes.

Ridge: coeficientes pequeños son más plausibles que coeficientes extremos.

Ridge como estimador MAP

Supongamos el modelo normal:

$$\mathbf{y} \mid \beta, \sigma^2 \sim N(X\beta, \sigma^2 I).$$

Entonces:

$$-\log p(\mathbf{y} \mid \beta) \propto \frac{1}{2\sigma^2} \|\mathbf{y} - X\beta\|_2^2.$$

Ahora asumimos un prior gaussiano independiente para los coeficientes:

$$\beta_j \sim N(0, \tau^2).$$

Entonces:

$$-\log p(\beta) \propto \frac{1}{2\tau^2} \|\beta\|_2^2.$$

Interpretación bayesiana de Ridge

El estimador MAP minimiza:

$$\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \frac{1}{2\tau^2} \|\boldsymbol{\beta}\|_2^2.$$

Multiplicando por una constante positiva, esto es equivalente a minimizar:

$$\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2,$$

donde

$$\lambda = \frac{\sigma^2}{\tau^2}.$$

Por tanto, Ridge es el estimador MAP bajo un prior normal centrado en cero.

Solución MAP de Ridge

Como el problema MAP de Ridge coincide con la función objetivo Ridge, su solución es:

$$\hat{\beta}_{MAP} = \hat{\beta}_{Ridge} = (X^T X + \lambda I)^{-1} X^T \mathbf{y}.$$

La misma fórmula admite dos lecturas:

- lectura frecuentista: solución de un problema de mínimos cuadrados penalizados;
- lectura bayesiana: moda posterior bajo prior normal para los coeficientes.

Lectura conceptual del prior Ridge

El prior gaussiano expresa la creencia de que, antes de observar los datos, los coeficientes probablemente son moderados y están alrededor de cero.

No dice que los coeficientes sean exactamente cero.

Por eso Ridge encoge los coeficientes, pero usualmente no elimina variables.

Interpretación bayesiana de LASSO

LASSO también puede interpretarse como estimación MAP.

Mantenemos la misma verosimilitud normal:

$$\mathbf{y} \mid \beta, \sigma^2 \sim N(X\beta, \sigma^2 I).$$

La diferencia está en el prior. Para LASSO usamos un prior Laplace independiente:

$$\beta_j \sim \text{Laplace}(0, b).$$

Este prior concentra mucha probabilidad cerca de cero y, al mismo tiempo, permite algunos coeficientes relativamente grandes.

Derivación MAP de LASSO

La densidad Laplace puede escribirse como:

$$p(\beta_j) = \frac{1}{2b} \exp\left(-\frac{|\beta_j|}{b}\right).$$

Para todos los coeficientes:

$$p(\beta) \propto \exp\left(-\frac{1}{b} \sum_{j=1}^p |\beta_j|\right).$$

Por tanto:

$$-\log p(\beta) \propto \frac{1}{b} \sum_{j=1}^p |\beta_j|.$$

Combinando verosimilitud normal y prior Laplace, el MAP minimiza:

$$\frac{p}{b}$$

Cómo se estima el MAP en LASSO

El estimador MAP de LASSO se define como:

$$\hat{\beta}_{MAP} = \arg \max_{\beta} p(\beta \mid \mathbf{y}).$$

Luego se transforma en el problema equivalente:

$$\hat{\beta}_{LASSO} = \arg \min_{\beta} \{ \|\mathbf{y} - X\beta\|_2^2 + \lambda \|\beta\|_1 \}.$$

A diferencia de Ridge, este problema no tiene una solución cerrada simple debido a la no diferenciabilidad de $|\beta_j|$ en cero. Por eso se estima habitualmente mediante descenso por coordenadas o métodos proximales.

El prior Laplace concentra más masa cerca de cero que el prior normal y tiene colas más pesadas.

Esto favorece que algunos coeficientes sean estimados exactamente como cero, mientras permite que otros permanezcan relativamente grandes.

LASSO: muchos coeficientes pequeños o nulos, pocos coeficientes relevantes.

Comparación bayesiana

Método	Prior sobre β_j	Interpretación
Ridge	Normal centrado en cero	Coefficientes moderados son más probables
LASSO	Laplace centrado en cero	Muchos coeficientes cercanos o iguales a cero
Elastic Net	Combinación conceptual L1–L2	Selección más estabilidad

La interpretación bayesiana permite entender la penalización como una forma explícita de incorporar información previa sobre la magnitud esperada de los coeficientes.

- Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning*.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*.
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso.
- Hoerl, A. y Kennard, R. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems.
- Zou, H. y Hastie, T. (2005). Regularization and Variable Selection via the Elastic Net.